


## Distribuciones muestrales



## Objetivo

Tomar decisiones o sacar conclusiones respecto a la población basándose en la información contenida en una muestra (observaciones).

Generalmente se hacen inferencias respecto a los parámetros que describen la distribución de la población, a la forma de la distribución, a la independencia entre variables, a la normalidad de las observaciones.

Tipos de inferencias que veremos:

- ▶ **Estimación Puntual**: Se da un solo valor o punto como estimación del parámetro poblacional de interés
- ▶ **Estimación por Intervalos**: Se especifica un intervalo de posibles valores del parámetro en estudio
- ▶ **Test de hipótesis**: Se hacen conclusiones acerca de una hipótesis sobre los parámetros o distribución de la población. (próxima unidad)

**Ejemplo:** Calcular el tiempo de respuesta de un analgésico para calmar dolores musculares.

No es factible por costos/tiempos/eficacia probar el analgésico en toda la población ⇒ realiza un **muestreo** a fines de considerar un subconjunto de observaciones de la población.

## Muestreo

- ▶ Una muestra es un subconjunto de una población
- ▶ Para que las inferencias que hagamos con ella sean válidas, debe ser aleatoria y representativa de la población bajo estudio.
- ▶ Se elige mediante un procedimiento de **muestreo**, que debe realizarse de manera muy cuidadosa respondiendo a preguntas tales como cuántos elementos? cómo? dónde?, etc.
- ▶ Distintas metodologías de muestreo (consultar bibliografía asignatura)

## Continuación Ejemplo

Luego de tomar una **muestra aleatoria** de pacientes y de haber registrado el tiempo de respuesta del analgésico en cada uno de ellos, si denotamos por  $\mu_T$  al valor esperado del tiempo de respuesta, podríamos arribar a conclusiones como:

- ▶ **Estimación Puntual:**  $\hat{\mu}_T = 35 \text{ m}$
- ▶ **Estimación por Intervalos:**  $\mu_T \in (32.3, 38.2)$
- ▶ **Test de hipótesis:**  $\mu_T > 31 \text{ m}$

dependiendo del método a utilizar según lo que se quiera informar.

# Distribuciones Muestrales

## Definición 10.1:

Si  $X_1, X_2, \dots, X_n$  es una colección de  $n$  variables aleatorias tales que:

1. cada una de ellas tiene la misma función de probabilidad que la distribución de la población,
2. son independientes entre sí,

entonces se dice que  $X_1, \dots, X_n$  son *variables aleatorias independientes e idénticamente distribuidas* (v.a.i.i.d.)

y constituyen una **muestra aleatoria** de la población (muestra aleatoria de tamaño  $n$ ).

# Definiciones y notaciones

## Definición 10.2

Un **estadístico** es una función de variables aleatorias que constituyen una o más muestras.

Ejemplo:  $\bar{X}$  = media muestral de la muestra  $X_1, X_2, \dots, X_n$ .  
(Notar que un estadístico también es una variable aleatoria).

## Definición 10.3: Distribución Muestral

La distribución de probabilidades de un estadístico se denomina **distribución muestral**

## Observación

La **distribución muestral** de un estadístico depende de la distribución de la población, del tamaño de la muestra, etc.

# Distribuciones muestrales

## Distribuciones Muestrales

Sean  $X_1, X_2, \dots, X_n$  v.a.i.i.d. con  $E(X_i) = \mu$ ,  $Var(X_i) = \sigma^2$ ,  
 $\forall i = 1, \dots, n$ ,  $0 < \sigma^2 < \infty$ .

1.  $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$  es la **media muestral** de la muestra aleatoria  $X_1, X_2, \dots, X_n$ .
2.  $S_n = \sum_{i=1}^n X_i$  es el **total muestral** de la muestra  $X_1, X_2, \dots, X_n$ .

$\bar{X}$

- ▶  $\mu_{\bar{X}} = E(\bar{X}) = \mu$
- ▶  $\sigma_{\bar{X}}^2 = Var(\bar{X}) = \frac{\sigma^2}{n}$

$S_n$

- ▶  $\mu_{S_n} = E(S_n) = n\mu$
- ▶  $\sigma_{S_n}^2 = Var(S_n) = n\sigma^2$

# Distribuciones muestrales

Sean  $X_1, X_2, \dots, X_n$  v.a.i.i.d. con  $E(X_i) = \mu$ ,  $Var(X_i) = \sigma^2$ ,  
 $\forall i = 1, \dots, n$ ,  $0 < \sigma^2 < \infty$ .

- ▶ Si **no** conocemos la distribución de la población, **no** podemos, en general, calcular la distribución de los estadísticos construidos a partir de  $X_1, X_2, \dots, X_n$  .
- ▶ **SI** podemos determinar la esperanza y varianza de los principales estadísticos en función de los parámetros de la distribución de la población.

# Distribución de la media muestral $\bar{X}$

Sean  $X_1, X_2, \dots, X_n$  v.a.i.i.d. con  $E(X_i) = \mu$ ,  $Var(X_i) = \sigma^2$ ,  
 $\forall i = 1, \dots, n$ ,  $0 < \sigma^2 < \infty$ .

**Situaciones:**

1.  $E(\bar{X}) = \mu$  y  $Var(\bar{X}) = \sigma_{\bar{X}}^2 = \frac{\sigma^2}{n}$  donde  $E(X)$  y  $\sigma^2$  son parámetros poblacionales.
2. Si  $n > 30$  entonces podemos usar **TCL** y  $\bar{X} \approx \mathcal{N}(\mu, \sigma^2/n)$
3. Si se asume que la población tiene distribución normal  $\Rightarrow X_1, X_2, \dots, X_n \sim \mathcal{N}(\mu, \sigma^2)$  y  $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n)$  independientemente del valor de  $n$

## Ejemplo 1

El nivel de colesterol total en una población se distribuye normalmente con una media de 210 mg/dL y una varianza de 400 ( $\text{mg/dL}$ )<sup>2</sup>. Se extrae una muestra aleatoria de tamaño 16 de esa población. Calcular la probabilidad que la media muestral supere a la media poblacional en por lo menos 8 mg/dL.

## Continuación Ejemplo 1

Datos:

- ▶ La población se distribuye **normalmente**, esto es,  $X \sim \mathcal{N}(\mu, \sigma^2)$  con  $\mu = 210$ ,  $\sigma^2 = 400$ .
- ▶ Se toma una muestra  $X_1, \dots, X_n$  con  $n=16$

Preguntas: Si  $\bar{X} = \frac{\sum_{i=1}^{16} X_i}{16}$

1.  $P(\bar{X} > \mu + 8) = ?$
2. ¿Cuál es la distribución de  $\bar{X}$ ?

## Continuación Ejemplo 1

Respuestas:

2. Como la población es normal, y las  $X_i$  una muestra aleatoria de esa población, entonces  $\bar{X} \sim \mathcal{N}(\mu, \sigma^2/n) = \mathcal{N}(200, 400/16)$

1.  $P(\bar{X} > \mu + 8) = P(\bar{X} > 210 + 8) = 1 - P(\bar{X} \leq 218) =$   
 $1 - P\left(\frac{\bar{X} - \mu_{\bar{X}}}{\sigma_{\bar{X}}} \leq \frac{218 - \mu_{\bar{X}}}{\sigma_{\bar{X}}}\right) = 1 - \Phi(8/5) = 1 - \Phi(1.6) = 0.0548$

# Distribución de la proporción muestral

## Supuestos

- ▶ Población finita, formada por elementos de dos clases.
- ▶  $N$ = tamaño de la población,  $N_1$  cantidad de elementos de clase 1,  $N_2$  cantidad de elementos de clase 2,  $N = N_1 + N_2$
- ▶ Se toma una muestra de tamaño  $n$ , interesa conocer cuántos elementos de la clase 1 (éxitos) hay en esa muestra
- ▶ Se define  $X$ = número de elementos de la clase 1 presentes en la muestra
- ▶ La **proporción poblacional** de éxitos es  $p = \frac{N_1}{N}$  (parámetro)
- ▶ La **proporción muestral** de éxitos es  $\hat{p} = \frac{X}{n}$  (estadístico)

$$P(\hat{p} = \frac{r}{n}) = P\left(\frac{X}{n} = \frac{r}{n}\right) = P(X = r)$$

# Distribución de la proporción muestral

Si la extracción de la muestra se hace:

1. Con reemplazo  $\Rightarrow \hat{p}$  tiene distribución Binomial, y  
 $E(\hat{p}) = p = \frac{N_1}{N}$ ,  $Var(\hat{p}) = \frac{pq}{n}$
2. Sin reemplazo  $\Rightarrow \hat{p}$  tiene distribución hipergeométrica, y  
 $E(\hat{p}) = p = \frac{N_1}{N}$ ,  $Var(\hat{p}) = \frac{pq}{n} \cdot \frac{N-n}{N-1}$
3. Si  $n \geq 100 \Rightarrow$  por Teo. DeMoivre-Laplace  $\hat{p} \approx \mathcal{N}(\hat{p}, \frac{\hat{p}\hat{q}}{n})$

## Ejemplo 2

En un grupo de 80 personas, 30 son hipertensas (el resto no). Se extrae una muestra aleatoria, sin reemplazo, de 8 personas.

1. encontrar la distribución de probabilidad de la proporción  $\hat{p}$  de hipertensos presentes en la muestra
2. calcular  $P(0.5 \leq \hat{p} \leq 0.7)$
3. calcular  $E(\hat{p})$  y  $Var(\hat{p})$
4. Si la población hubiera sido de 800 personas, de las cuales 300 son hipertensas y tomaba una muestra de 100 personas, ¿como podría aproximar la distribución de  $\hat{p}$ ?

## Continuación Ejemplo 2

Datos:

- $N=80$  personas,  $N_1=30$  personas hipertensas,  $N_2=50$  personas no hipertensas,
- Se extrae una muestra aleatoria de tamaño  $n=8$ , sin reemplazo

Sea  $X =$  número de personas hipertensas en la muestra (que se toma sin reemplazo)  
⇒  $X \sim h(n, N_1, N)$  y

$$P(\hat{p} = \frac{r}{n}) = P(X = r) = \frac{\binom{N_1}{r} \binom{N - N_1}{n - r}}{\binom{N}{n}} = \frac{\binom{30}{r} \binom{50}{8 - r}}{\binom{50}{8}}$$

1.

$r$	0	1	2	3	4	5	6	7	8
$\hat{p}$	$\frac{0}{8}$	$\frac{1}{8}$	$\frac{2}{8}$	$\frac{3}{8}$	$\frac{4}{8}$	$\frac{5}{8}$	$\frac{6}{8}$	$\frac{7}{8}$	$\frac{8}{8}$
$P(\hat{p} = \frac{r}{n})$	0.0185	0.1034	0.2384	0.297	0.218	0.096	0.025	0.0035	0.0002

2.  $P(0.5 \leq \hat{p} \leq 0.7) = P(4 \leq X \leq 5.6) == P(X = 4) + P(X = 5) = 0.314$

3.  $E(\hat{p}) = \frac{N_1}{N} = \frac{30}{80} = \frac{3}{8}$ ,  $Var(\hat{p}) = \frac{(N_1/N) \cdot (1 - N_1/N)}{n} \cdot \frac{N-n}{N-1} = 0.03$

4. Por De Moivre - Laplace,  $\hat{p} \approx \mathcal{N}\left(\frac{3}{8}, 0.002\right)$

## Distribución $\chi^2$

Sea  $X_1, \dots, X_n$  muestra aleatoria de una distribución normal con media  $\mu$  y varianza  $\sigma^2$ . Entonces  $Z_i = \frac{X_i - \mu}{\sigma}$  son v.a. independientes con distribución normal estándar y la v.a definida como


$$\sum_{i=1}^n Z_i^2 = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2$$

tiene distribución  $\chi^2$  con  $n$  grados de libertad.

Si  $Y \sim \chi_n^2 \Rightarrow E(Y) = n, \text{Var}(Y) = 2n$

# Distribución $\chi^2$

Distribucion Chi cuadrada



## Distribución $\chi^2$

Sea  $X_1, \dots, X_n$  muestra aleatoria de una distribución normal con media  $\mu$  y varianza  $\sigma^2$ . Si  $\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$ ,  $S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n-1}$ , entonces

$$\frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{(n-1)S^2}{\sigma^2}$$


tiene distribución  $\chi^2$  con  $(n-1)$  grados de libertad. Además  $\bar{X}$  y  $S^2$  son v.a. independientes.

# Cálculo de Probabilidades

Supongamos  $\chi^2 \sim \chi^2_n$ . Para calcular probabilidades debe recurrirse a tablas que dan valores aproximados. Fijado  $0 < \alpha < 1$  se define el *valor de porcentaje*  $\chi_{\alpha,n}^2$  como

$$P(\chi^2 > \chi_{\alpha,n}^2) = \alpha$$

# Cálculo de Probabilidades $\chi^2$



# Uso de tabla $\chi^2$




Table III Percentage Points  $\chi_{\alpha, v}^2$  of the Chi-Squared Distribution

$v \backslash \alpha$	.995	.990	.975	.950	.900	.500	.100	.050	.025	.010	.005
1	.00+	.00+	.00+	.00+	.02	.45	2.71	3.84	5.02	6.63	7.88
2	.01	.02	.05	.10	.21	1.39	4.61	5.99	7.38	9.21	10.60
3	.07	.11	.22	.35	.58	2.37	6.25	7.81	9.35	11.34	12.84
4	.21	.30	.48	.71	1.06	3.36	7.78	9.49	11.14	13.28	14.86
5	.41	.55	.83	1.15	1.61	4.35	9.24	11.07	12.83	15.09	16.75
6	.68	.87	1.24	1.64	2.20	5.35	10.65	12.59	14.45	16.81	18.55
7	.99	1.24	1.69	2.17	2.83	6.35	12.02	14.07	16.01	18.48	20.28
8	1.34	1.65	2.18	2.73	3.49	7.34	13.36	15.51	17.53	20.09	21.96
9	1.73	2.09	2.70	3.33	4.17	8.34	14.68	16.92	19.02	21.67	23.59
10	2.16	2.56	3.25	3.94	4.87	9.34	15.99	18.31	20.48	23.21	25.19
11	2.60	3.05	3.82	4.57	5.58	10.34	17.28	19.68	21.92	24.72	26.76
12	3.07	3.57	4.40	5.23	6.30	11.34	18.55	21.03	23.34	26.22	28.30
13	3.57	4.11	5.01	5.89	7.04	12.34	19.81	22.36	24.74	27.69	29.82
14	4.07	4.66	5.63	6.57	7.79	13.34	21.06	23.68	26.12	29.14	31.32

# Uso de tabla $\chi^2$

Ejemplos:

1. Encontrar los valores de los siguientes percentiles:  
 $\chi^2_{0.05,10}$ ,  $\chi^2_{0.025,5}$ ,  $\chi^2_{0.95,8}$
2. Si  $\chi^2 \sim \chi^2_{11}$ , calcular  $P(\chi^2 > 17.28)$
3. En R invocar la función `pchisq(q, df, lower.tail = FALSE)`

## Distribución t

Sea  $Z$  v.a. normal estándar y sea  $\chi^2$  una v.a. chi cuadrada con  $\nu$  grados de libertad. Entonces si  $Z$  y  $\chi^2$  son independientes, la v.a. definida como

$$T = \frac{Z}{\sqrt{\chi^2/\nu}}$$

tiene una **distribución t con  $\nu$  grados de libertad.**

$$\mu = E(T) = 0, \text{ Var}(T) = n^2 - 2$$

# Distribución t

